

Learning Disabilities



שמות המגישים:

טלי מיכאלי: מספר ת"ז- 20608844

רון אפריאט: מספר ת"ז- 322614926

איהאב מריד: מספר ת"ז- 211843123

אליקה בוצ'קריוב: מספר ת"ז- 215365370

סער אביבי: מספר ת"ז- 207881350

תוכן עניינים:

3: Learning Disabilities - הנושא
4 Smart Autism Watch
	Eye-tracking based Detection of Developmental Dyslexia in Children Using
8Convolutional-Transformer Network
12ADHD detection using EEG
	How can handwriting be used to accurately detect and distinguish between dyslexia and
16dysgraphia?
	Enhancing Early Diagnosis of Autism Spectrum Disorder in Children: A Comparative Analysis of
19 Machine Learning Techniques
24: (SRS) מסמך אפיון
28 השוואה בין הטכניקות
31: Learning disabilities - עבור הנושא
32: RA ניתוח והפקת לקחים
33 ביבליוגרפיה

הצגת הנושא - Learning Disabilities :

בחרנו להתמקד בנושא לקויות למידה בשל השפעתו הרחבה והעמוקה על ילדים, מתבגרים ומבוגרים. לקויות למידה כוללות מגוון הפרעות נוירו־התפתחותיות, כגון הפרעת קשב וריכוז (ADHD), דיסלקציה, ואוטיזם (ASD), אשר משפיעות על היכולת לרכוש, לעבד ולהשתמש במידע בצורה תקינה. לקויות אלו מלוות לעיתים קרובות בקשיים קוגניטיביים, רגשיים וחברתיים, וללא התערבות מתאימה עלולות להשפיע לרעה על הצלחה לימודית, תעסוקתית ואישית.

למרות המודעות ההולכת וגדלה לנושא, אבחון מדויק של לקויות למידה עדיין מהווה אתגר משמעותי. שיטות האבחון הקיימות נשענות לעיתים על מדדים סובייקטיביים ודיווחי הורים או מורים, דבר שעלול להוביל לאבחונים שגויים או מאוחרים. בעבודתנו חקרנו גישות חדשניות ומגוונות לאבחון ותמיכה באנשים עם לקויות למידה – החל משימוש באותות EEG לזיהוי ADHD, דרך ניתוח תנועות עיניים או כתיבה לאבחון דיסלקציה, ועד לטכנולוגיות לבישות כגון שעון חכם או אלגוריתמים חכמים לאיתור מוקדם של אוטיזם. שילוב טכנולוגיות מתקדמות בהנדסת דרישות פותח פתח לדיוק, יעילות והתאמה אישית טובה יותר של פתרונות חינוכיים וטיפולים.

שאלות המחקר:

- מהי הטכנולוגיה הטובה ביותר ללמידה מיטבית של ילדים עם אוטיזם (ASD) מרחוק?
- כיצד ניתן לאבחן דיסלקציה בדיוק גבוה?
- כיצד ניתן לאתר הפרעת קשב וריכוז (ADHD)?
- מהו הפתרון הטוב ביותר לזיהוי מוקדם של אוטיזם (ASD)?
- כיצד ניתן להשתמש בכתב יד כדי לזהות ולהבחין באופן מדויק בין דיסלקציה לדיסגרפיה?

טכניקות:

- The Smartwatch Autism Spectrum Data Scheme (SM-ASDS)
- Rasterized eye-tracking heat-maps run through a CNN-Transformer to classify dyslexia risk.
- Detection of Attention Deficit Hyperactivity Disorder (ADHD) using EEG.
- A comparative analysis between classification algorithms for early ASD detection.
- RNN with LSTM - Sequential pattern detection in handwriting.

Smart Autism Watch

הצגת הנושא:

הפרעת הספקטרום האוטיסטי (ASD - Autism Spectrum Disorder) היא לקות נוירו התפתחותית מורכבת, המתבטאת בקשיים בתקשורת, הבנה חברתית, התנהגות חברתית, ותחומי עניין מצומצמים. ילדים עם ASD מתמודדים עם אתגרים משמעותיים ברכישת מיומנויות בסיסיות כגון קריאה, כתיבה, הקשבה ודיבור. בהתאם לכך, תוכניות הלימוד עבורם חייבות להיות מותאמות אישית ולהתחשב ברגישויות החושיות, בקצב הלמידה האינדיבידואלי וביכולות הוויסות העצמי.

לצורך כך פותח Smart Autism Learning System, מערכת חכמה מבוססת טכנולוגיות loMT (Internet of Medical Things) וסביבות לימוד מרחוק מבוססות Edge שמטרתה לתמוך בלמידה מותאמת אישית לילדים עם אוטיזם, באמצעות שעון חכם לביש הכולל חיישנים המנטרים את פעילות הילד, מנתחים אותה ומעדכנים את התוכנית הלימודית בהתאם.

הבעיה של RASS :

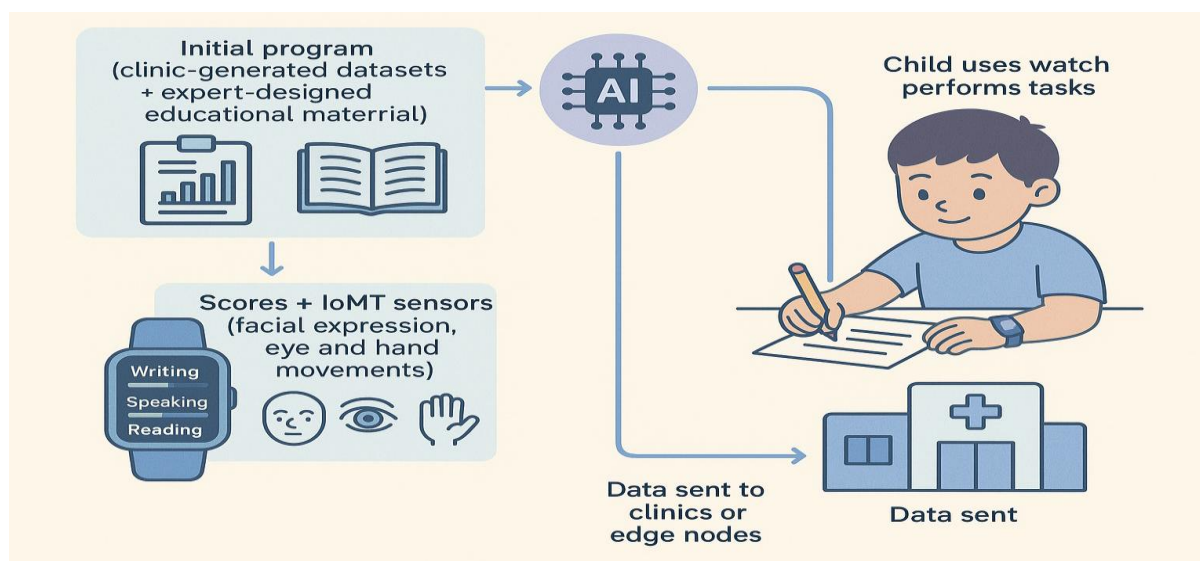
ילדים עם אוטיזם זקוקים להתאמות מתמשכות בלמידה. כיום, ברוב המסגרות הלימודיות אין יכולת לעקוב בזמן אמת אחרי התקדמות הילד, להבין את רמת הקשב והתגובה שלו למשימות לימודיות או להתאים את התוכן לקשיים תחושתיים וחברתיים. בנוסף, מערכות קיימות מתמקדות בעיקר בזיהוי האבחנה (ASD) באמצעים קליניים כמו EEG או ראיונות, ומתעלמות מדפוסי הלמידה בפועל של הילד.

מכאן נגזרת שאלת המחקר:

כיצד ניתן לשפר את תהליך הלמידה של ילדים עם ASD באופן מותאם אישית ודינמי (מרחוק)?

הטכניקה לפתרון:

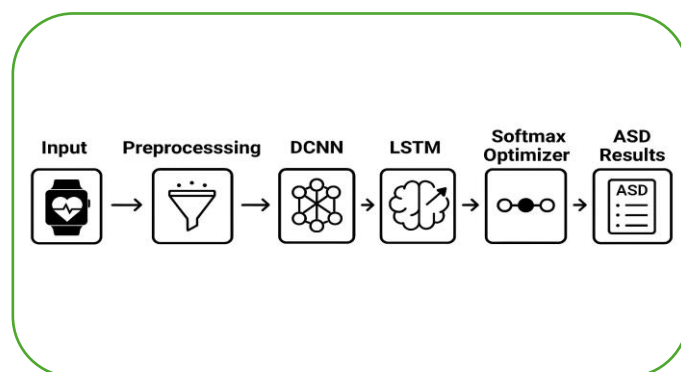

המערכת המוצעת - SM-ASDS (Smartwatch Autism Spectrum Data Learning Scheme) - מבוססת על שעונים חכמים המחוברים למכשירי קצה (edge nodes) ולמרכזי מידע רפואיים/חינוכיים. היא כוללת:



- חיישני loMT לשמיעת הקלטות, תנועות גוף, קרבה, תנועות עיניים ועוד.
- עיבוד מקדים (Preprocessing) של נתונים גולמיים וסינון רעשים.
- שילוב של רשתות עצביות מסוג DCNN (Convolutional Neural Networks) ו ALSTM (Adaptive Long Short-Term Memory) לזיהוי תבניות בזמן.
- מערכת אופטימיזציה של זמני תגובה, משאבי מחשוב ודיוק.
- Offloading (דינמי) – חלק מהנתונים מעובדים בשעון, חלק במובייל וחלק נשלחים לקצה (Edge) לעיבוד מתקדם.

הדגמת טכניקות – תרחיש שימוש:

ילד בן 8 המאובחן עם ASD לובש שעון חכם אשר מנטר את תגובותיו תוך כדי שיעור קריאה אינטראקטיבי (אפליקציית קריאה).
המערכת מבצעת את הפעולות הבאות :



1. Input – בשלב זה השעון החכם אוסף נתונים בזמן אמת באמצעות חיישני loMT מובנים:

מטרת הניטור	מה נמדד בפועל	סוג קלט
זיהוי של קושי שפתי, קושי בהגייה או חוסר הבנה	בדיקת איכות הקריאה בקול – האם הילד מדבר ברור, האם יש הפסקות ארוכות או חזרתיות	קול (Audio)
הערכת רמת הקשב והמעורבות בפעילות	ניתוח מיקוד המבט – האם הילד מסתכל על התוכן, על סביבתו או מסיט את העיניים	תנועת עיניים
זיהוי מצבי תסכול, אי־שקט תחושותי או גירוי יתר	תזוזות, תנועות ידיים חוזרות או תנועות יתר	תנועות גוף
איתור עומס קוגניטיבי, עיכוב בעיבוד שמיעתי או חזותי	מידת פרק הזמן שלוקח לילד להגיב להנחיות	זמן תגובה (Latency)
בחינת הבנת הנאמר ובדיקה של יכולת הבחנה שמיעתית	האם הילד מזהה מילים מוקלטות או מגיב לצלילים מסוימים	תגובה לגירוי שמיעתי

2. Preprocessing - כדי שהנתונים יהיו ניתנים לניתוח מדויק, המערכת מבצעת פעולות כמו:

- סינון רעשים (למשל רעשי רקע בקול)
- ניתוח רכיבים בלתי תלויים – (ICA) להפרדת אותות (כמו מצמוץ מהקול)
- נרמול ערכים (כדי שכל קלט יהיה ביחס אחיד)

המטרה היא להפוך את הנתונים ה"גולמיים" לנקיים, מדויקים וסטנדרטיים לעיבוד מתקדם.

3. DCNN – Deep Convolutional Neural Network

- מזהה תבניות חזותיות שמיעתיות בתוך הקלטים (כמו שינוי בקול או מבט ממושך)
- מעבד מידע במרחב – למשל איפה הילד מסתכל, ואיך הדיבור שלו משתנה בזמן.

4. ALSTM – Adaptive Long Short-Term Memory

- מזהה דפוסים לאורך זמן (רצפים)
- מזהה אם ההתנהגות משתנה לאורך השיעור – לדוגמה, האם הילד מגלה עייפות לקראת הסוף.

שילוב בין השניים: מאפשר הבנה גם של הרגע הספציפי וגם של הקשר הכללי לאורך זמן.

5. Adaptive Offloading + החלטה בזמן אמת –

כאן המערכת:

- מעריכה האם הילד מגיב היטב או לא.
- מחליטה האם להמשיך במשימה הנוכחית או לעבור לגירוי אחר(למשל מסיפור ויזואלי למשחק).
- מחלקת עומס החישוב בין השעון, הטלפון, והשרתים לפי כמות המידע והזמינות

6. פלט – לאחר שהמערכת אספה, עיבדה וניתחה את התגובות של הילד – מגיע שלב הפלט

(Output), שבו מתקבלות החלטות בזמן אמת על בסיס המידע שנלמד. הפלט הוא תוצאה של כל השלבים הקודמים, והוא כולל שלוש שכבות פעולה:

מזב למידה	פירוט התנהגותי	תגובה מצד המערכת
מרוכז (Focused)	הילד מגיב בצורה מהירה, ממוקדת ונכונה למשימות הלימוד	המשך ישיר של הפעילות הקיימת
מתקשה (Struggling)	מופיעות תגובות איטיות, טעויות חוזרות ונראה שהילד מוסח בקלות	מעבר למשימה קצרה יותר או הצגת תוכן חזותי במקום מילולי
מוצף (Overwhelmed)	סימנים לתחושת עומס – תנועות חזרתיות, הימנעות מהמסך, תגובות פיזיות לא רגילות	הפסקה זמנית בפעילות או מעבר לפעילות רגועה ומרגיעה
מנותק (Idle/Disconnected)	היעדר תגובה לאורך זמן, חוסר מעורבות או התנתקות מהפעולה	שליחת התראה למורה, הורה או מטפל רלוונטי

המערכת בוחרת באופן אוטומטי את המשימה הבאה מתוך מאגר מותאם לילד, לפי נתוני הלמידה, הקושי הנוכחי, וההיסטוריה של הילד (לדוגמא: אם הילד קרא סיפור והתבלבל במילים, המערכת תציע משחק זיהוי תמונה-מילה/אם הילד לא הגיב כלל, המערכת תעבור למצב "מנוחה חושית" עם מוזיקה שקטה או צבעים רכים).

ולבסוף, נשלח דוח למורה, תרפיסט או הורה, עם נתונים חשובים:

- אחוז הצלחה
- תזמוני תגובה
- רמות קושי
- המלצות להמשך

Eye-tracking based Detection of Developmental Dyslexia in Children Using Convolutional-Transformer Network

הצגת הנושא:

דיסלקציה התפתחותית (DD) היא לקות למידה ספציפית הפוגעת ביכולת קריאה שוטפת, איות וכתיבה, ומחייבת זיהוי מוקדם להתערבות יעילה. המודלים המסורתיים נשענים על מבחני קריאה / כתיבה או הדמיות מוח (MRI / fMRI / EEG) הדורשים מומחי תחום או סובלים ממגבלות עלות ודיוק, ולכן פחות נוחים לפריסה רחבה בבתי-ספר. פתרון מוצע: שימוש ב-Eye-tracking וגוישה חזותית ישירה לציון מסלולי העין בזמן קריאה, ללא שלב ארוך של הפקת תכונות ידניות. המודל החדש מציג דיוק SOTA של 98.21% בזיהוי דיסלקציה חוצה-נבדקים על בסיס מסלולי עיניים גולמיים, ומכון לכלי סינון יומיומי בבתי-ספר.

ההבחנה נעשית בין קבוצת סיכון גבוהה (HR) וקבוצת סיכון נמוכה (LR) של ילדים בגיל 9-10, תוך הדגשת הצורך בבניית מודלים מדויקים וחסכוניים לעיבוד. הבסיס המדעי: מסלולי עיניים משקפים דפוסי קריאה – ילדים בסיכון נוטים לזמן קריאה כולל ארוך יותר, סקאדות קצרות יותר ורגרסיות רבות.

שאלת מחקר: (RASS) האם המרה חזותית ישירה של מסלולי עין גולמיים + ארכיטקטורת Convolutional-Transformer היברידית (ללא הנדסת תכונות מפורשת) מאפשרת שיפור מובהק בדיוק זיהוי דיסלקציה בין HR ל-LR, תוך פשטות קדם-עיבוד ושרידות לרוחב נבדקים? (נימוקים בהמשך: יעילות, דיוק, חסכון בהנדסת תכונות).

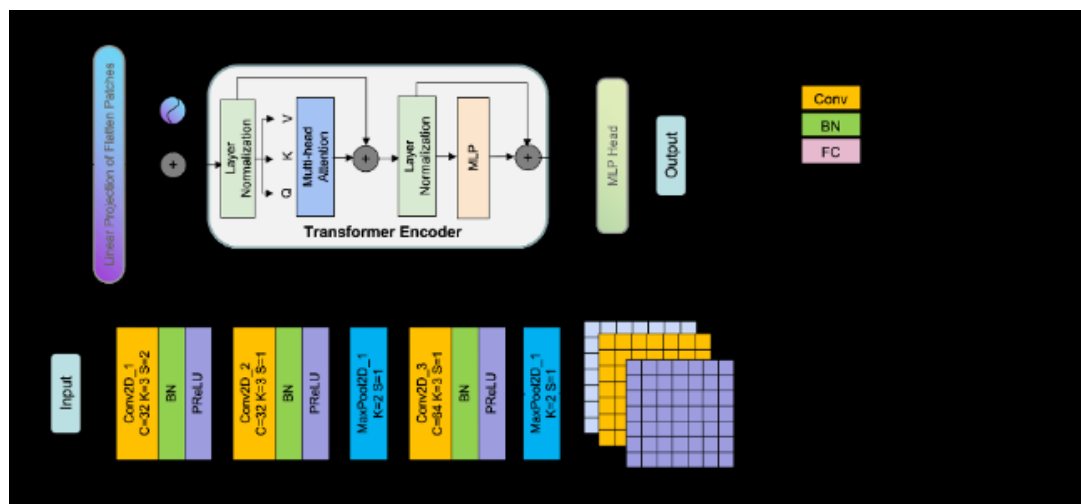
הטכניקה לפתרון:

- הצגת הגישה הכללית: המרה של סדרות (X, Y) לשתי העיניים לייצוגי תמונה אחידים 128×128 של מסלול העין לאורך זמן, ללא שלב הנדסת תכונות מלאכותי.
- אחידות תחום וצמצום רעש: נרמול טווחי צירים, מיצוע בין עין ימין ושמאל להפחתת עודפות ושיפור חסינות.
- ויזואליזציה יעילה: בחירה בייצוג (שיטה שנייה) המבהיר זמן קריאה, רגרסיות וסקאדות לעומת ייצוג כרונולוגי "מבולגן".
- הפקת טוקנים מקומית: שלוש שכבות Convolution מפיקות מפות $16 \times 28 \times 28$ המחולקות ל-16 טלאים (patches) בגודל $7 \times 7 \times 16 \rightarrow$ השטחה והיטל לינארי לממד 784 (טוקנים חזותיים).
- הוספת מידע מיקום ו-Class Token: הזרקת positional embeddings וטוקן סיווג לפני מעבר דרך שכבות Transformer מרובות ראשי-קשב.
- מודל היברידי CNN + Self-Attention: קונבולוציות לתבניות מקומיות יציבות; קשב רב-ראשי לתלות ארוכת-טווח במסלול העין.
- פרמטריזציה ארכיטקטונית: בלוק Transformer עם 6 שכבות, 8 ראשים, אקטיבצית GELU ; ראש MLP עם טבלת שכבת softmax.

- אימון ואופטימיזציה: Conv2D + BN, Momentum SGD (0.9), לומדות: $0.001 \rightarrow 0.01 \rightarrow 0.1$ (בשלבם – לאחר 40 אפוקים, 80 אפוקים, ו-80 > בהתאמה).
 - הערכת ביצועים: שימוש במדדי Accuracy, TPR, TNR; ניסוי חוצת-נבדקים.
 - דיוק ותוצאות – TPR 99.23%, TNR 97.06%, Accuracy 98.21%; שיפור על פני שיטות קודמות (SVM-RFE, CNN-Feature, Spectrum+CNN).
 - תרומת הארכיטקטורה (אבלציה): הסרת CNN $\rightarrow 95.29\%$ מודל CNN בלבד \rightarrow ; הסרת Attention $\rightarrow 94.37\%$ (ממחיש שמיזוג מקומי+גלובלי קריטי).
 - יתרונות ליבה: ללא DCT / padding להשלמת אורך (פשטות), ללא סינון אות (שימור מידע + חוסן), שימוש בנתונים מקוריים בלבד.
- הדגמת טכניקות (פירוט מדורג):
- שלב ראשון – יצירת ייצוגי מסלול עין: (Visualization & Normalization)
- א. זיהוי שהייצוג הכרונולוגי הגולמי "מבולגן" ואינו מבדיל היטב.
 - ב. המרה לשיטה השנייה: פרישת הקואורדינטות לפי זמן, איחוד טווחי צירים לכל הנבדקים, מיצוע בין עיניים להפחתת שונות ועודפות.
 - ג. קיבוע רזולוציה 128×128 למניעת עיוות סקיילינג ושימור פרטים עדינים במסלול.
 - ד. תוצאה: תמונות בהן ניתן לחלץ ויזואלית פערי זמן קריאה, רגרסיות וסקאדות (לרוב HR ארוך יותר LR, סקאדות מהירות בציר Y).
- שלב שני – המרת תמונה לטוקנים: (Convolutional Feature Map Embedding)
- 3 שכבות Conv2D מפיקות מפה $16 \times 28 \times 28$, חלוקה ל-16 טלאים $7 \times 7 \times 16 \rightarrow$ השטחה והיטל לממד 784 (וקטורי טוקן).
- שלב שלישי – קידוד רצף והרחבת הקשר: (Transformer Layers)
- הוספת: positional embeddings + class token; רצף הטוקנים עובר 6 שכבות Transformer (Multi-Head Attention + MLP) ללכידת תלות ארוכת טווח.
- שלב רביעי – למידת דפוסים היברידית: (Hybrid CNN-Transformer Rationale)
- הסינרגיה: קונבולוציות \rightarrow קורלציות מקומיות יציבות \rightarrow Attention; אינטגרציית דפוסים גלובליים / פיזור זמני לא טיפוסי.
- שלב חמישי – ראש סיווג: (MLP Head & Metrics)
- ראש MLP (Softmax) מפיק הסתברויות לשתי מחלקות LR / HR; הערכה במדדי Accuracy, TPR, TNR על תת-קיפולים מרובים.
- שלב שישי – אימון ואופטימיזציה:
- BN לשיפור קונברגנציה SGD; עם Momentum תזמון קצב למידה בשלבים $(0.1 \rightarrow 0.01 \rightarrow 0.001)$.

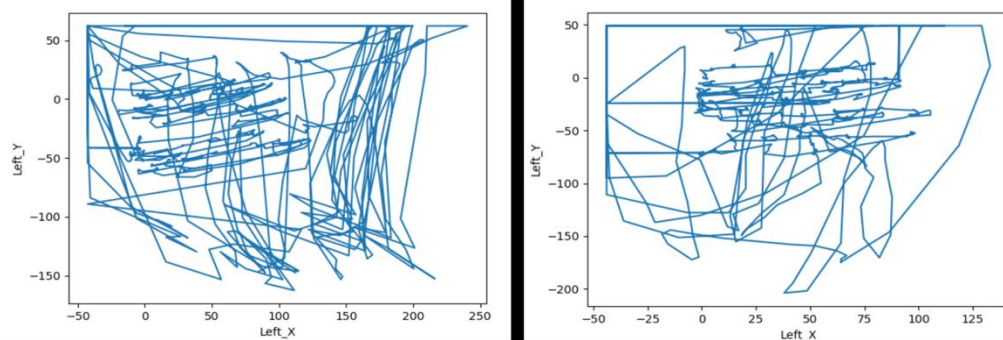
שלב שביעי – אבלציה להערכת תרומת רכיבים:
הצגת ירידת ביצועים בהסרת מודולים מאששת חשיבות (CNN תכונות מקומיות) ו- Attention תלות גלובלית) ושילובם .

שלב שמיני – יתרונות מערכתיים ויישומיים:
ללא הנדסת תכונות ידנית / Padding / סינון → פשטות, פחות שגיאות החדרה, תגובה מהירה וחוסן בין-נבדקי .




תובנה רלוונטית לדיסלקציה	תפקיד	רכיב
מקודדת קיבועים, (fixations) סקאדות, ורגרסיות	מציגה את מסלול המבט עבור קטע קריאה יחיד	תמונת מסלול מבט קלט
לוכדים אשכולות של קיבועים ארוכים או סקאדות מהירות	מחלצים מוטיבים מרחביים מקומיים	בלוקי קונבולוציה (3×)
משמרים סדר מרחבי של אירועי המבט	ממירים מפה תכונות לרצף טוקנים	(Patch Embedding) + קידוד מיקום
מדגיש תבניות כמו רגרסיות חוזרות או דילוגים לא סדירים	מדגם תלות ארוכת-טווח דרך self-attention	מקודד (6 שכבות) Transformer
מאגד תכונות שנקלטו לקבוצת סיכון (ציון סיכון)	מפיק הסתברות HR / LR	ראש MLP

תבניות תנועת עיניים מדגמות:



איור 3 – קורא בסיכון נמוך

התקדמות חלקה משמאל לימין עם קיבועים קצרים ואחידים ומעט רגרסיות – מעיד על פענוח (decoding) שוטף.



איור 4 – קורא בסיכון גבוה

ריבוי קיבועים ארוכים וסקאדות לאחור (רגרסיות) יוצר עקיבה צפופה ומשוננת. אשכולות "טווח-עין" מורחבים אלו מסמנים קושי בפענוח, אופייני לדיסלקציה.

תוצאות מסכמות: דיוק 98.21% – (TNR 97.06%, TPR 99.23%) עליונות לעומת שיטות קודמות בטבלה (למשל. Spectrum feature + CNN 96.6%).

משפט מסכם: צינור ה-Visualization המנרמל מסלולי עין (שלבים 1–2) מזין ארכיטקטורת Convolutional-Transformer היברידית (שלבים 3–5) הנתמכת באופטימיזציה יעילה (שלב 6) ומאומתת בניתוח אבליציה (שלב 7) – שילוב זה מאפשר זיהוי דיסלקציה מדויק במיוחד ללא הנדסת תכונות ידנית מורכבת (שלב 8).

ADHD detection using EEG

הצגת הנושא:

הפרעת קשב וריכוז (ADHD - Attention Deficit Hyperactivity Disorder) היא אחת מהלקויות הנפוצות והתפתחותיות הנפוצות ביותר בקרב ילדים ומתבגרים. מדובר בהפרעה כרונית המתבטאת בקשיי קשב, אימפולסיביות ולעיתים גם בהיפראקטיביות. תסמינים אלו משפיעים על תפקוד יומיומי, הישגים לימודיים וחברתיים, ועלולים להימשך גם לגיל הבגרות.

למרות חשיבות האבחון, השיטות המקובלות כיום מתבססות בעיקר על שאלונים, ראיונות ותצפיות, שיטות סובייקטיביות העלולות להוביל לאבחון שגוי. מאמר זה מציג שיטה חדשנית המבוססת על ניתוח אותות EEG (אלקטרואנצפלוגרם- נתוני גלי מוח הנמדדים באמצעות אלקטרודות המתחברות לקרקפת), כבסיס לאבחון.

הבעיה של RASS:

אבחון ADHD מהווה אתגר מתמשך בתחום הרפואה, הפסיכולוגיה והחינוך, שכן אבחון מאוחר או שגוי עלול להוביל לפגיעות משמעותיות ברמה האישית והחברתית. כיום, אבחון ADHD מבוססים על הערכות סובייקטיביות (שאלונים, ראיונות ותצפיות התנהגותיות) שתלויות בגורמים חיצוניים, מידת שיתוף הפעולה של הנבדק ואינטואיציה המאבחן. כתוצאה מכך, יתכנו הטיות, חוסר דיוק ואף פספוס אבחנתי.

לפיכך, שאלת המחקר העיקרית היא: כיצד ניתן לצמצם את שיעור האבחונים השגויים של ADHD באמצעות ניתוח אותות EEG בשילוב במודלים ניורונים מתקדמים?

הטכניקה לפתרון:

המאמר מציג שיטת אבחון חדשנית להפרעת קשב וריכוז (ADHD) המבוססת על ניתוח אותות EEG באמצעות טכניקות מתקדמות של עיבוד אותות ולמידת מכונה.

השיטה כוללת מספר שלבים מרכזיים:

- עיבוד מוקדם Preprocessing- סינון רעשים וניתוח רכיבים בלתי תלויים (ICA) – שיטה להפרדת אותו לפי מקורם) לניקוי EEG.
- יצירת מטריצות קישוריות- בניית ייצוגים מרחביים של קשרים בין ערוצי EEG בכל חלון זמן (גודל של 19×19).
- טרנספורמציות DCT- דחיסת המידע לחילוף תכונות עיקריות מתוך מטריצות הקלט (DCT) Dynamic Connectivity Tensors – שיטה לייצוג מידע בתדרים, בדומה ל-JPEG).
- ConvLSTM- רשת ניורונים מסוג Convolutional LSTM (שילוב של קונבולוציה וזיכרון קצר-ארוך לזיהוי תבניות מרחביות זמניות באותות).
- מנגנון Attention- רכיב המאפשר למודל להתמקד באזורים קריטיים במידע ולשפר את הדיוק על ידי מתן "משקל" גבוה יותר לתכונות חשובות.
- שכבת פלט- קביעה אם לנבדק יש הפרעות קשב וריכוז (ADHD) או לא.

השילוב בין שלבים אלה מאפשר אבחון ADHD מדויק יותר (99.75% דיוק) על בסיס ניתוח של אותות EEG בלבד.

הדגמת טכניקות:

מקרה לימוד קבוצתי: מדגם הכולל 91 ילדים בגילאי 7-12, בהם 46 ילדים המאובחנים עם הפרעות קשב וריכוז (ADHD) ו-45 ילדים בקבוצת ביקורת. במהלך המחקר, הילדים התבקשו לבצע משימה חזותית קצרה, במהלכה נאספו אותו EEG (רישום חשמלי של פעילות מוחית) שנמדדו באמצעות 19 אלקטרודות המחוברות לקרקפת. הנתונים נאספו בפרקי זמן של 30 שניות ונמדד בתדר דגימה של 512Hz.

להלן פירוט שלבי יישום המודל על בסיס מקרה לימוד פרטני, בהתאם לסוגי הישויות הרלוונטיים:

שלב ראשון - Preprocessing: בשלב זה מתבצעת פונקציה של עיבוד מוקדם על אובייקטי הקלט - אותות EEG שנמדדו מהנבדק במסגרת מקרה הלימוד הקבוצתי. המטרה המרכזית היא לשפר את איכות המידע שנקלט, כך שיהיה מתאים לעיבוד מדויק בשלבים הבאים. הפעולות כוללות סינון רעשים חיצוניים (כגון תנועות שרירים ופעילות לב), הסרת רעשים ביולוגיים פנימיים (כגון מצמוצים ותנועות עיניים) באמצעות ניתוח רכיבים בלתי תלויים (Independent Component Analysis (ICA) - שיטה סטטית להפרדת מקורות האותות), וכן הפחתת השפעת הולכת נפח (Volume Conduction) באמצעות שיטת Current Source Density (CSD), אשר מדגישה פעילות מקומית ומפחיתה השפעות משותפות על ערוצים סמוכים.




Fig. 4. Time domain and Power spectrogram of an instance of the data.





Fig. 2. Power spectral density of an instance of EEG recordings before filtering.

האיורים שמעל מדגימים את ניתוח הנתונים בשלב העיבוד המוקדם. בצד שמאל מופיע האות כפי שנמדד במרחב הזמן (Time Domain), ובמרכז מופיע ספקטרוגרמה המדגימה את התפלגות התדרים לאורך 30 שניות. מימין מוצגת צפיפות ההספק (Power spectral Density) לפי ערוץ, אשר מאפשרת לזהות רעשים בתדרים בעייתיים (למשל רעש קווי סביב 50Hz). תצוגות אלו שימשו כבסיס לקביעת מסננים מתאימים ולהסרת רכיבים מזוהמים באותות.

שלב שני - Dynamic Connectivity Tensor (DCT): בשלב זה מתבצעת פונקציה של הפקת ייצוגים מרחביים-זמניים (spatiotemporal) מתוך אותות EEG שהם האובייקט שנמדד מהנבדקים במסגרת מקרה הלימוד הקבוצתי. הנתונים מחולקים לחלונות זמן של שנייה אחת, ועל כל חלון מבוצע חישוב מתאם בין כל זוג ערוצים, לצורך יצירת טנסור קישוריות דינמית (DCT) – מבנה תלת מימדי המתאר את יחסי הגומלין בין אזורים במוח לאורך זמן. המטרה בשלב זה היא להפחית את ממדי הנתונים תוך שימור מאפיינים חיוניים שיאפשרו למודל לזהות תבניות פעילות מוחית ייחודיות להפרעת קשב וריכוז.

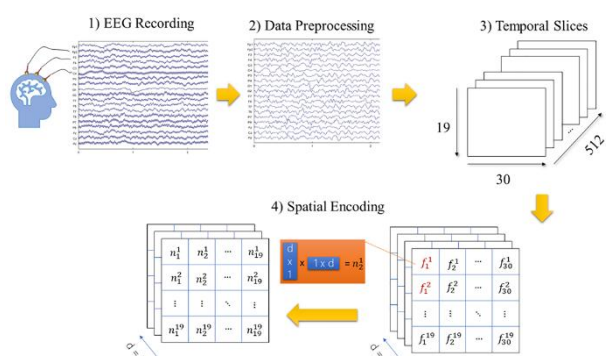


Fig. 3. The proposed feature extraction scheme.

האיור מציג את תהליך שלב 2: חיתוך האותות לחלונות זמן וחישוב קשרים בין ערוצים לצורך יצירת ייצוג מרחבי-זמני של פעילות מוחית.

שלב שלישי - Convolutional Long Short-Term Memory (ConvLSTM): בשלב זה מופעלת פונקציית למידה על גבי האובייקט המרכזי שהוא טנסור הקלט שהופק בשלב הקודם מתוך נתוני EEG שנמדדו במסגרת מקרה הלימוד הקבוצתי. הטנסור מוזן לרשת נוירונים מסוג ConvLSTM, אשר משלבת עיבוד מרחבי (Convolution) עם עיבוד סדרתי של מידע לאורך זמן (LSTM). רשת זו מותאמת במיוחד ללמידה של תבניות מרחביות זמניות בנתונים מרובי ממדים, ומטרתה לזהות דפוסים חבויים הקשורים להפרעת קשב וריכוז, אשר לא ניתנים לזיהוי בשיטות אבחון קלאסיות.

שלב רביעי - Attention Mechanism: בשלב זה מיושמת פונקציה של הקצאת משקל דיפרנציאלי באמצעות מנגנון Attention, על רצף התכונות שהופק מרשת ConvLSTM ומתבסס על נתוני EEG שנאספו במסגרת מקרה הלימוד הקבוצתי. מטרת המנגנון היא לאפשר למודל להתמקד במקטעים המהותיים ביותר בתוך רצף הנתונים, כלומר להבליט את אותם מאפיינים שתורמים להבחנה בין ילדים המאובחנים עם ADHD לבין קבוצת הביקורת. שלב זה תורם לשיפור יכולת ההכללה של המודל ולהגברת הדיוק של תהליך הסיווג.

שלב חמישי - Classification Output: לבסוף, מתבצעת פונקציית סיווג המבוססת על המאפיינים שנלמדו בשלבים הקודמים, באמצעות רצף התכונות שעבר דרך מנגנון הAttention ומתבסס על נתוני EEG שנאספו במסגרת מקרה הלימוד הקבוצתי. הסיווג הוא בינארי: בעל הפרעות קשב וריכוז (ADHD) או לא. תהליך זה מתבצע באמצעות שכבת פלט המחוברת לרשת Fully Connected. מטרת השלב היא להפיק החלטה חד משמעית בהתבסס על מידע ביולוגי בלבד, ללא צורך בהערכות סובייקטיביות מצד הורים, מורים או אנשי מקצוע. על פי תוצאות המאמר, המודל השיג דיוק ממוצע של 99.75%, המעיד על יכולת הבחנה גבוהה בין הקבוצות.




Fig. 6. Proposed ConvLSTM with Attention mechanism.

האיור מתאר את תהליך הסיווג המלא: מהרשת המרחבית זמנית ConvLSTM (שלב 3), דרך מנגנון Attention להתמקדות באותות מייצגים (שלב 4), ועד לשכבת הפלט הסופית שמבצעת סיווג בינארי (שלב 5).

How can handwriting be used to accurately detect and distinguish between dyslexia and dysgraphia?

הצגת הנושא:

דיסלקסיה ודיסגרפיה הן לקויות למידה שמשפיעות באופן עמוק על יכולות הקריאה, הכתיבה ועיבוד השפה. דיסלקסיה פוגעת בעיקר בקריאה, ומתבטאת בקשיים בזיהוי מילים ועיבוד פונולוגי, כאשר אנשים מתקשים לחבר צלילים לאותיות המתאימות להם. דיסגרפיה, לעומת זאת, משפיעה על כישורי הכתיבה ומביאה לקשיים ביצירת אותיות, ברווח וביישור. הקיום המשותף של דיסלקסיה ודיסגרפיה מסבך את האבחון ודורש גישה מתחכמת המסוגלת להסתגל למורכבויות אלה תוך זיהוי והבחנה מדויקים בין ההפרעות.

מחקר זה משתמש בדפוסים גיאומטריים מתקדמים וברשתות עצביות חוזרות (RNN) כדי לזהות חריגות בכתב יד המעידות על דיסלקסיה ודיסגרפיה. כתב היד עובר תחילה סטנדרטיזציה, ולאחר מכן מתבצעת חילוץ מאפיינים המתמקד בסטיות קו הבסיס, קישוריות אותיות, עובי משיכות ואחריגות נוספות. מאפיינים אלה מוזנים לאחר מכן לרשת עצבית חוזרת המבוססת על אוטו-אנקודר כדי לזהות אי-סדירויות. התוצאות הראשוניות מדגימות את יכולתו של מודל RNN זה להשיג ביצועים המתקדמים ביותר בזיהוי משולב של דיסלקסיה ודיסגרפיה, תוך הצגת האתגרים הקשורים בהתאמת דפוסים מורכבים של למידה עמוקה לקורפוס מגוון של כ-33,000 דגימות כתיבה.

RNN רשת עצבית חוזרת: רשת עצבית שמעבדת רצפי נתונים ו"זוכרת" מידע מקלטים קודמים, מה שהופך אותה למתאימה לעבודה עם טקסט, דיבור או כל נתון שבו הסדר חשוב.

LSTM זיכרון לטווח ארוך קצר : שיפור של RNN שיכול לזכור מידע חשוב לתקופות ארוכות ולשכוח נתונים לא רלוונטיים, מה שהופך אותו לאידיאלי לעיבוד רצפים ארוכים כמו טקסט או כתב יד.

הטכניקה לפתרון:

במאמר נעשה שילוב של רשתות נוירונים רקורסיביות (RNN) עם אנליזה גיאומטרית של כתב יד באמצעותם נעשה זיהוי דיסלקסיה ודיסגרפיה.

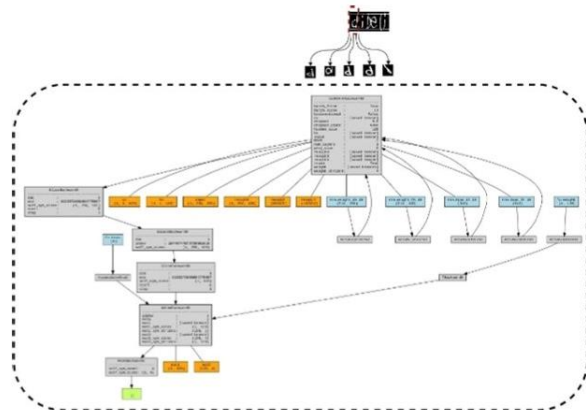
השיטה כוללת מספר שלבים מרכזיים:

- שלב 1 - הכנת הנתונים ועיבוד מקדים: החוקרים אספו 33,000 דוגמאות כתב יד מקטגוריות שונות (רגיל, דיסלקסיה, דיסגרפיה). כל התמונות הומרו לגווי אפור ושוננו לגודל אחיד של 256x256 פיקסלים. הנתונים עברו נרמול וחולקו ל-80% אימון ו-20% בדיקה.
- שלב 2 - חילוץ מאפיינים גיאומטריים: המערכת מנתחת מאפיינים ייחודיים בכתב היד כולל סטיות מקו הבסיס, מרווחים בין אותיות, שינויים בעובי הקו, היפוכי אותיות וסיבובים. המערכת מזהה דפוסים חריגים המאפיינים דיסלקסיה ודיסגרפיה.
- שלב 3 - בניית מודל-RNN אוטואנקודר: המודל מבוסס על שכבות LSTM ללכידת רצפים זמניים בכתביה. הוא כולל אנקודר לדחיסת המידע ודקודר לשחזורו, עם פונקציית אובדן מותאמת הכוללת עונשים על סטיות קיצוניות.

- שלב 4 - אימון והערכה: המודל עבר אימון באמצעות אופטימיזציית Adam ומסווג את הכתיבה לארבע קטגוריות. ההערכה מתבצעת באמצעות מטריצות בלבול, מדידת דיוק וציון F1.

תוצאה: המחקר השיג שיפור של 1% לעומת גישות CNN קיימות, עם יכולת מעולה לזהות דפוס כתיבה חריגים ורצפים זמניים.

הגרף מציג את הארכיטקטורה של רשת נוירונים רקורסיבית (RNN) במהלך תהליך ה-backpropagation - כאשר נתונים זורמים דרך שכבות שונות מלמעלה למטה. ניתן לראות שכבות LSTM (בכתום) ושכבות עיבוד נוספות (בכחול) המחוברות ברצף, עם חזרות וקשרים מורכבים המאפיינים רשתות רקורסיביות שלומדות



הדגמת טכניקות: זיהוי דיסלקציה ודיסגרפיה באמצעות RNN וניתוח דפוסים גיאומטריים

מדגם הכולל 33,000 דוגמאות כתב יד מקטגוריות שונות: כתיבה רגילה, דיסלקציה, דיסגרפיה פוטנציאלית נמוכה ודיסגרפיה פוטנציאלית גבוהה. הדוגמאות נעו מאותיות בודדות ועד משפטים שלמים, והתבססו על מסדי נתונים מרובים שנאספו ממחקרים קודמים. הנתונים חולקו ל-80% אימון ו-20% בדיקה לצורך אימות תוצאות המודל.

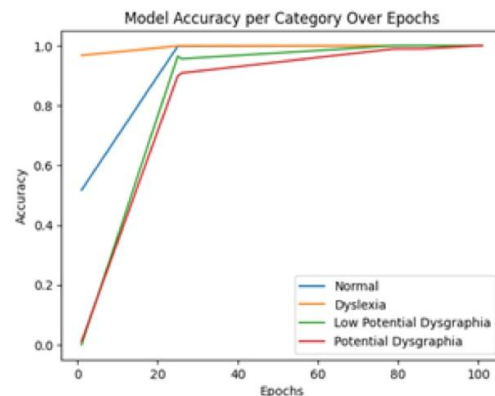
להלן פירוט שלבי יישום המודל על בסיס מקרה לימוד פרטני, בהתאם לסוגי הישויות הרלוונטיים:

שלב ראשון: Image Preprocessing - בשלב זה מתבצעת פונקציה של עיבוד מוקדם על תמונות כתב יד שנסרקו מהנבדקים. המטרה היא לסטנדרט את התמונות ולמזער הטיית שעוללות להשפיע על דיוק הזיהוי. הפעולות כוללות המרת התמונות לגווני אפור, שינוי גודל לרזולוציה אחידה של 256x256 פיקסלים ונרמול ערכי הפיקסלים. תהליך זה מבטיח שהמודל יתמקד במאפייני הכתיבה עצמה ולא בפרמטרים טכניים של הסריקה.

שלב שני: Geometric Feature Extraction - בשלב זה מתבצעת פונקציה של חילוץ מאפיינים גיאומטריים ספציפיים מתוך תמונות כתב היד. המערכת מנתחת סטיות מקו הבסיס, בוחנת בעיות קישוריות דרך מדידת מרווחים בין אותיות ומזהה שינויים בעובי הקו. בנוסף, המערכת מזהה סיבובי אותיות והיפוכים טיפוסיים לדיסלקציה ומחשבת מדדי צפיפות כתיבה כללית. כל המאפיינים נאספים למילון המכיל מידע קריטי על ליקויי הכתיבה.

שלב שלישי: RNN-Autoencoder Architecture - בשלב זה מופעלת פונקציית למידה על מילון המאפיינים שהופק בשלב הקודם. המאפיינים מוזנים לרשת נוירונים רקורסיבית עם שכבות LSTM המיועדות ללכידת תלויות זמניות ברצפי הכתיבה. הארכיטקטורה כוללת מבנה אוטואנקודר שדוחס את המידע החיוני ומשחזר את הנתונים לצורתם המקורית. רשת זו לומדת לזהות דפוס כתיבה חריגים וחוסר עקביות שאופייניים לדיסלקציה ודיסגרפיה.

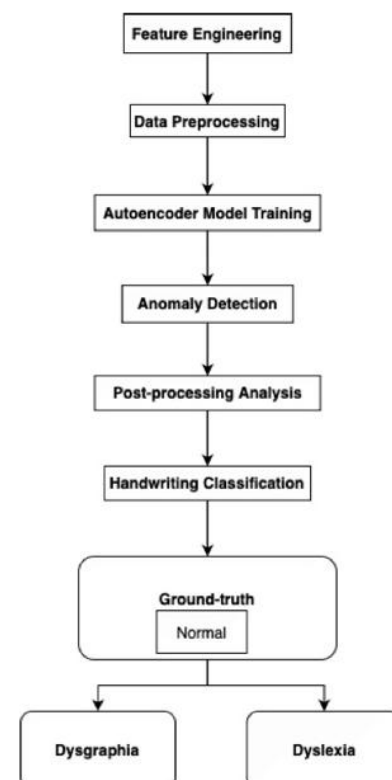
הגרף מציג את שיפור הדיוק של המודל לאורך 100 תקופות אימון (epochs) עבור ארבע קטגוריות כתיבה שונות. ניתן לראות שכתובה רגילה (כחול) ודיסלקציה (כתום) מגיעות מהר לדיוק גבוה, בעוד דיסגרפיה פוטנציאלית נמוכה (ירוק) ופוטנציאלית (אדום) לוקחות יותר זמן להגיע לדיוק מקסימלי, כאשר כל הקטגוריות מסיימות בדיוק של כמעט 100%.



שלב רביעי: Sequential Pattern Analysis - בשלב זה מיושמת פונקציה של ניתוח רצפים זמניים באמצעות שכבות LSTM על המאפיינים שחולצו. מטרת הניתוח היא לזהות דפוסי זרימה בכתיבה ואיך מעבר מאות אחת לאחרת משפיע על איכות הכתיבה. המערכת לומדת לזהות את ההבדלים בין זרימת כתיבה טבעית לדפוסי "קפיצות" וחוסר עקביות שמאפיינים דיסגרפיה. כמו כן היא מזהה דפוסי תיקונים והיסוסים שמאפיינים דיסלקציה.

שלב חמישי: Multi-Class Classification Output - לבסוף, מתבצעת פונקציית סיווג מרובה קטגוריות לארבע קטגוריות: כתיבה רגילה, דיסלקציה, דיסגרפיה פוטנציאלית נמוכה וגבוהה. הסיווג מתבסס על פונקציית אובדן מותאמת הכוללת עונשים נוספים על סטיות קיצוניות מקו הבסיס ובעיות קישוריות חמורות. מטרת השלב היא החלטה מדויקת המבוססת על ניתוח אובייקטיבי של דפוסי כתיבה ללא הערכות סובייקטיביות. המודל השיג שיפור של 1% לעומת גישות CNN קיימות בזכות יכולת RNN ללכוד תלויות זמניות ורצפים.

הגרף מציג את זרימת העבודה (workflow) של מערכת זיהוי חריגות כתב יד, החל מהנדסת מאפיינים (Feature Engineering) ועיבוד מקדים של נתונים, דרך אימון מודל אוטואנקודר וזיהוי חריגות, ועד לסיווג סופי של כתב היד. בסוף התהליך המערכת מסווגת את הכתיבה לשלוש קטגוריות עיקריות: רגיל (Normal), דיסגרפיה (Dysgraphia) ודיסלקציה (Dyslexia), כאשר כל קטגוריה מתבססת על ניתוח מקיף של מאפיינים גיאומטריים וחריגות שזוהו במהלך התהליך.



Enhancing Early Diagnosis of Autism Spectrum Disorder in Children: A Comparative Analysis of Machine Learning Techniques

הצגת הנושא:

הפרעת הספקטרום האוטיסטי (ASD) היא לקות נוירו-התפתחותית מורכבת, המלווה בקשיים בתקשורת, אינטראקציה חברתית והתנהגויות חזרתיות. אבחון מוקדם של ASD חיוני להתערבות יעילה ולשיפור איכות החיים של הילדים ובני משפחותיהם.

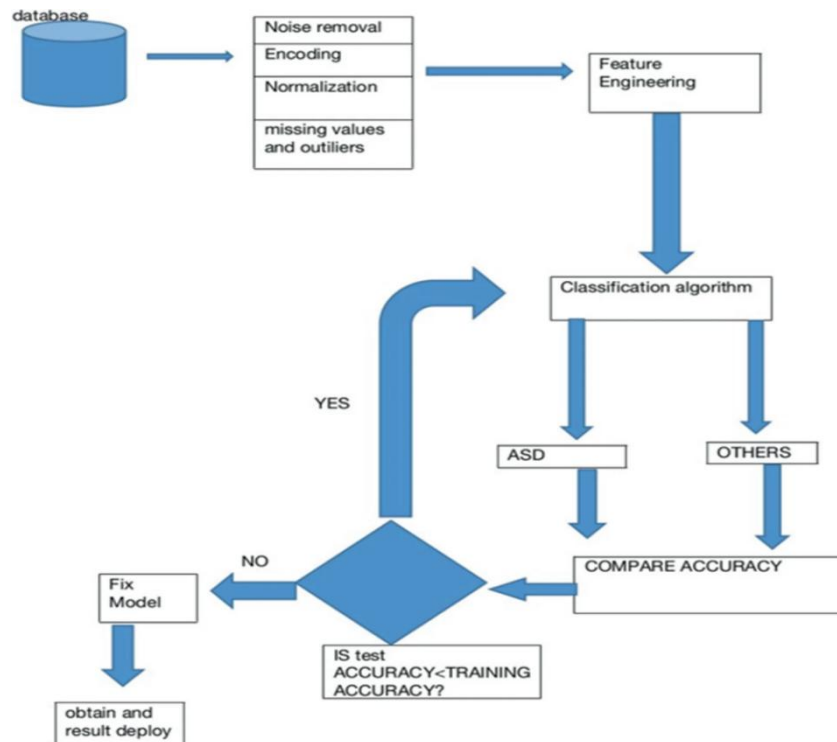
שאלת המחקר (RASS):

כיצד ניתן להשתמש במודלים של למידת מכונה, תוך השוואה בין מספר אלגוריתמים (כגון Random Forest, SVC, Logistic Regression), כדי לשפר את דיוק האבחון המוקדם של ASD על בסיס נתוני שאלון Q-CHAT-10?

הטכניקה לפתרון:

המחקר בחן מודלים קלאסיים של למידת מכונה על נתונים התנהגותיים מתוך מאגר Kaggle. המטרה הייתה להעריך אילו אלגוריתמים נותנים את הביצועים הטובים ביותר באבחון ASD. השלבים המרכזיים:

- איסוף נתונים: שימוש בגרסה מקוצרת של שאלון Q-CHAT (10 שאלות מפתח).
- עיבוד מקדים (Preprocessing): ניקוי נתונים, טיפול בערכים חסרים, קידוד משתנים קטגוריים ונרמול.
- בחירת מאפיינים (Feature Selection): זיהוי השאלות/המאפיינים בעלי ההשפעה הגבוהה ביותר.
- מודלים שנבחנו: Logistic Regression, Naive Bayes, SVC, Random Forest, KNN.
- מדדי הערכה: Accuracy, Precision, Recall, F1-Score.
- יישום ממשי: שימוש במודל שקיבלנו על מנת להעריך באופן המדויק ביותר את הסבירות לתסמונת אצל ילדים.



שלב 1 – איסוף נתונים (Input):

המערכת אוספת את תשובות ההורה לעשר השאלות המרכזיות (כמו "האם הילד מגיב כשקוראים בשמו?", "האם יש קשר עין בקלות?", "האם הילד מצביע על אובייקטים?"). כל תשובה מקודדת לערך מספרי (0 = לא, 1 = כן). אם יש נתונים חסרים או תשובות לא עקביות, המערכת מעלה התרעה ומבקשת השלמה.

שלב 2 – עיבוד מקדים (Preprocessing):

כדי שהמודל יוכל לעבוד על הנתונים, מתבצע:

- ניקוי נתונים: סילוק ערכים שגויים או כפולים.
- קידוד קטגוריות: המרה של תשובות מילוליות לערכים בינאריים.
- נרמול: התאמת ערכי הקלט כך שכל משתנה יהיה בטווח אחיד, לדוגמה 0–1.

שלב 3 – אימון מודלים (Modeling):

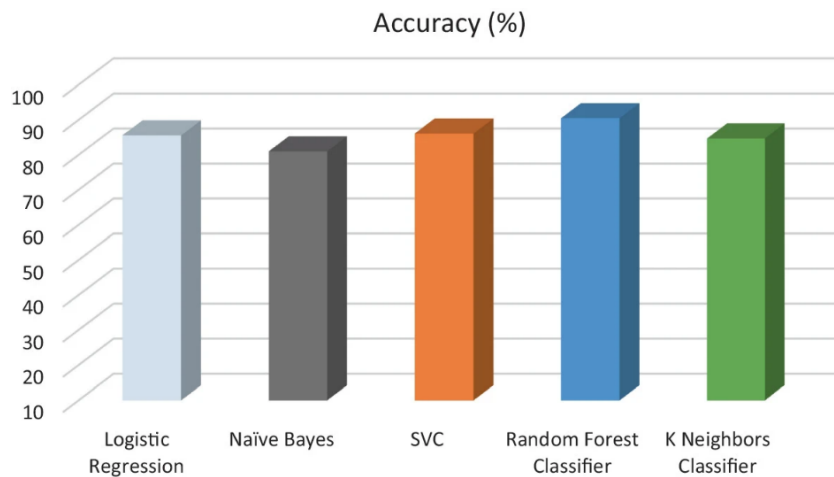
לאחר סיום העיבוד המקדים (Preprocessing), המערכת משתמשת במספר אלגוריתמים קלאסיים של למידת מכונה, שנבחרו בשל הצלחתם הקודמת במודלי סיווג דומים.

האלגוריתמים שנבחנו:

- Logistic Regression (רגרסיה לוגיסטית):

- מה הוא מחשב:
האלגוריתם מחשב הסתברות בין 0 ל-1, ומחליט על פי סף (threshold, למשל 0.5) אם הדגימה חיובית (ASD) או שלילית.
- יתרון:
פרשנות גבוהה – ניתן לראות אילו שאלות תרמו בצורה משמעותית לאבחון (באמצעות משקל הפיצ'ר).
- מתאים במיוחד כאשר יש חלוקה ברורה יחסית בין שתי הקבוצות.
- Naive Bayes:
מה הוא מחשב:
לכל קטגוריה (ASD או לא ASD) האלגוריתם מחשב את ההסתברות שהיא נכונה, ובוחר את הקטגוריה בעלת ההסתברות הגבוהה ביותר.
- יתרון: מהיר מאוד, מתאים לנתונים קטנים או פשוטים.
- חזק במיוחד במערכות עם נתונים קטנים יחסית.
- חסרון: ההנחה של אי-תלות לא תמיד תואמת לנתוני התנהגות כמו Q-CHAT.
- Support Vector Classifier (SVC):
איך זה עובד: האלגוריתם מחפש את "ההפרדה" (Hyperplane) המיטבית שמפרידה בין הקבוצות (ASD / לא ASD) במרחב התכונות.
- מה הוא מחשב:
SVC מחשב את מיקום הדגימה החדשה ביחס לגבול ההפרדה. אם היא נופלת בצד אחד – היא מוגדרת כ-ASD, אחרת לא.
- יתרון: יכולת סיווג גבוהה גם כשיש דמיון בין קבוצות.
- K-Nearest Neighbors (KNN):
איך זה עובד: KNN אינו "מאמן" מודל, אלא מבצע סיווג על סמך השוואה בין נקודת הדגימה לנקודות אימון קיימות. עבור כל דגימה חדשה, האלגוריתם מחשב את המרחק (לרוב מרחק אוקלידי) בין הדגימה לכל דגימה אחרת בסט האימון. בוחרים את ה-k שכנים הקרובים ביותר. ההצבעה (Majority Voting) מחליטה לאיזו קטגוריה הדגימה תשתייך.
- מה הוא מחשב: המרחקים בין נקודות – ובוחן מי השכנים הקרובים ביותר.
- יתרון: אין צורך בהנחות מוקדמות על הנתונים, פשוט להבנה וליישום.
- Random Forest Classifier:

- איך זה עובד: זהו אלגוריתם Ensemble (שילוב מודלים), שבו נבנים הרבה עצי החלטה (Decision Trees), וכל עץ מחליט בעצמו על הסיווג.
- מה הוא מחשב: כל עץ מחליט בנפרד על סיווג (ASD / לא ASD), והתוצאה הסופית היא הרוב.
- יתרון: דיוק גבוה, עמידות לרעש ויכולת לזהות אילו תכונות (שאלות) משפיעות הכי הרבה (Feature Importance).



שלב 4 – חישוב מדדי ביצועים (Evaluation):

לאחר שהמודלים מתאמנים, מחשבים מדדי ביצועים:

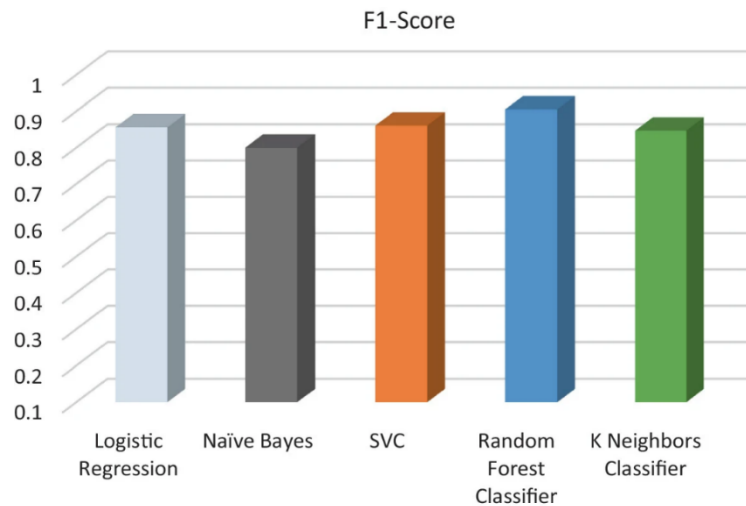
- Accuracy (דיוק): אחוז התחזיות הנכונות.

TP (True Positives): דגימות ASD שחזינו נכון. TN (True Negatives): דגימות לא-ASD

שחזינו נכון. FP (False Positives): ילדים בריאים שסווגו בטעות כ- ASD. FN (False

Negatives): ילדים עם ASD שסווגו בטעות כלא-ASD.

- Precision: מראה כמה מתוך כל הדגימות שסיווגנו כ-ASD באמת היו ASD. Recall: מראה כמה מתוך כל הילדים עם ASD הצלחנו לזהות. מדד חשוב כשלא רוצים לפספס ילדים עם ASD (מינימום False Negatives). F1-Score: ממוצע הרמוני של Precision ו-Recall. משלב בין Precision ו-Recall, במיוחד כשיש חוסר איזון בין הקטגוריות. ערך 1 הוא מושלם, 0 הוא כישלון מוחלט.



שלב 5 – תחזית בזמן אמת (Output):

כאשר הורה חדש ממלא את השאלון, המערכת:

- מזינה את התשובות למודל הטוב ביותר (במקרה שלנו זה Random Forest, שהציג 90.5% דיוק).
- מחזירה תחזית בינארית – "קיים חשד ל-ASD" או "לא קיים חשד" – יחד עם ציון הסתברות (למשל 85%).
- יוצרת דוח המלצות, כולל פירוט אילו שאלות תרמו לאבחון (Transparency).

שלב 6 – השוואה ובחירת מודל מיטבי:

בסיום ההרצה ההשוואתית, הוחלט במאמר כי Random Forest מציג את הביצועים האופטימליים, בעיקר בזכות יכולתו לשלב מאפיינים בצורה גמישה ולהימנע במידה מיטבית מהטיות שמאפיינות מודלים לינאריים.

מסמך אפיון (SRS Organized by feature):

Specific requirements 3.0

3.1 דרישות ממשק חיצוניות (External Interface Requirements):

:User Interface 3.1.1

המערכת תספק ממשק משתמש גרפי (GUI) המאפשר העלאת קבצים מסוגים שונים (EEG, תנועת עיניים, כתב יד, שאלונים) תתמוך בהצגת ניתוחים גרפיים, תובנות ניתנות להסבר, וכלי תמיכה בהחלטה עבור אנשי מקצוע.

:Hardware Interface 3.1.2

תמיכה באינטגרציה עם חיישנים יעודיים: Eye tracking (משקפי מעקב עיניים), EEG, שעונים חכמים, טאבלט עם עט דיגיטלי. הנתונים יוזרמו בזמן אמת או יועברו בעיבוד מקובץ תוך תאימות מלאה לעיבוד.

:Software Interface 3.1.3

המערכת תשלב מודולים לעיבוד נתונים (EEG, תנועת עיניים, כתב יד) עם אלגוריתמים כגון: CNN, ConvLSTM, RNN, Transformer, ועוד, בהתאם לסוג הנתונים. תתבצע השוואה בין המודולים לפי מדדי ביצוע (Recall, Precision, F1, דיוק, וכו').

:Communications Interface 3.1.4

תקשורת מאובטחת עם קליניקות, מכשירים לבישים, ממשקי הוראה מרחוק ושרתי ענן. פרוטוקולי התקשורת שיושמו (למשל: Bluetooth Low Energy, Https, MQTT, וכו') יבטיחו שלמות, זמינות וסודיות של הנתונים תוך שמירה על פרטיות וסנכרון.

:Functional requirements 3.2

System Feature 1 3.2.1 - סינון מוקדם:

:Purpose of feature 3.2.1.1

איתור ראשוני של סימנים ללקויות למידה או אוטיזם (ASD) בקרב ילדים, תוך שימוש בנתונים פשוטים ובסביבה חינוכית טבעית, ללא צורך בהתערבות פולשנית.

:Stimulus/Response sequence 3.2.1.2

- איסוף נתונים פשוטים: שאלונים (Q chat), הקלטות EEG קצרות, מעקב עיניים וכתב יד.
- עיבוד ראשוני של הנתונים והמרה למבנה נתונים אחיד לצורכי ניתוח.
- הפקת סיווג בינארי: אין חשד / יש חשד (נדרש אבחון נוסף).

:Associated functional requirements 3.2.1.3

- המערכת תאפשר תמיכה במספר מקורות קלט מסוגים שונים בהתאם למאפייני הלקויות למידה.
- המערכת תבצע נרמול וניקוי של נתוני הקלט באופן אוטומטי.
- תתקבל החלטה ראשונית תוך פחות מ-60 שניות, לפי פרמטרים שהוגדרו מראש.
- כל פלט יוצג בליווי המלצה: להמשיך כרגיל / לגשת לאבחון מלא.

:System Feature 2 3.2.1 - אבחון קליני מעמיק:

:Purpose of feature 3.2.1.1

אבחון מלא ומדויק בעזרת שילוב חיישנים מתקדמים ואלגוריתמים מותאמים לסוג הלקות.

:Stimulus/Response sequence 3.2.1.2

- קליטת נתונים מרובי ערוצים: EEG מלא, מעקב עיניים דו עיני, כתב יד כתמונה.
- ניתוח מותאם לקבוצת אבחנה (ADHD, דיסגרפיה, דיסלקציה, ASD) לפי אלגוריתם רלוונטי.
- הצגת תוצאות הסתברותיות ותובנות קליניות במסך ניתוח ייעודי לאנשי מקצוע.

:Associated functional requirements 3.2.1.3

- כל סוג אבחנה יתבצע בעזרת מודל ייעודי בהתאם ללקות.
- המערכת תתמוך בזיהוי מרובה קטגוריות ואחוזי ודאות לכל אבחנה.
- תופק הצגה גרפית של הממצאים (EEG, תנועת עיניים, כתב יד).
- נתוני הפלט יישמרו לניתוח עתידי / שיתוף עם גורמים טיפוליים.

:System Feature 3 3.2.1 - התאמת תוכנית לימודים אישית:

:Purpose of feature 3.2.1.1

בניית תוכנית לימוד מותאמת אישית בהתאם ליכולות ולמגבלות של הנבחן, בהתבסס על תוצאות האבחון, תוך מעקב בזמן אמת אחר תפקודו הלימודי.

:Stimulus/Response sequence 3.2.1.2

- חיבור שעון חכם לצורך מדידת ביצועים לימודיים: קריאה, כתיבה, האזנה ודיבור.
- איסוף נתונים פאסיביים (מבט, תנועות פנים, זמן תגובה וכו').
- בניית תוכנית למידה מבוססת AI תוך התאמה לסגנון לימוד אישי.

:Associated functional requirements 3.2.1.3

- המערכת תאפשר ניטור רציף של תפקוד המשתמש במצבים שונים.
- כל תוכנית תותאם לפרופיל הקוגניטיבי והמוטורי של הילד.
- תמיכה בייצוא דוחות עבור הורים / אנשי טיפול / מורים.
- תתאפשר התאמה אוטומטית לפי מגמות התקדמות.

System Feature 4 3.2.1 - אופטימיזציה ושיפור מתמשך מבוסס נתוני משתמש:

:Purpose of feature 3.2.1.1

עדכון ושיפור מתמיד של אלגוריתמים אבחוניים ותוכניות למידה מותאמות, באמצעות ניתוח נתוני שימוש מצטברים שמגיעים ממכשירים חכמים וממשובי אנשי מקצוע. מטרת המודול היא להבטיח שהמערכת לומדת לאורך זמן ומשתפרת בהתאמה לצרכים דינמיים של אוכלוסיות מגוונות.

:Stimulus/Response sequence 3.2.1.2

- המערכת אוספת באופן שוטף נתונים אנונימיים על הצלחות/כשלים בביצוע משימות למידה.
- הנתונים עוברים ניתוח לזיהוי תבניות שגיאה, מגמות קשב בזמן, ורמות הצלחה לפי אוכלוסייה.
- מתקיים אימון מחדש (retraining) של מודלים קיימים לשיפור דיוק האבחון וההתאמה.
- נשלחות המלצות ועדכונים לתוכניות הלמידה עבור תלמידים דומים.
- נשמרת עמידה בתקני פרטיות, אתיקה, ושקיפות אלגוריתמית.

:Associated functional requirements 3.2.1.3

- המערכת תתמוך באימון מחדש של מודלים על בסיס נתונים חדשים באופן מחזורי.
- המערכת תבצע התאמה דינמית לתלמידים מרקע שונה (שפה, מוגבלות גישה, שונות נוירולוגית).
- המערכת תזהה דפוסים שיטתיים של שגיאות והתקדמות ותפיק מהם מסקנות.
- המערכת תשלב משוב מאנשי מקצוע וממערכות קצה לצורך שיפור מתמיד.
- המערכת תספק לוג פעילות מתועד לצרכי ביקורת, פרטיות ואמינות.

:Performance requirements 3.3

- אותות EEG מ-19 ערוצים בתדר של 512Hz יעובדו תוך פחות מ-3 שניות.
- נתוני מעקב עיניים (FPS 60-30) יאובחנו עם פחות מ-5% איבוד פריימים.
- ניתוח כתב יד יושלם תוך 5 שניות לדגימה.
- זיהוי ADHD (מבוסס EEG): לפחות ב-99% דיוק בסיווג.
- דיסלקציה ודיסגרפיה: דיוק מעל 92%.
- סקר מוקדם ל-ASD (באמצעות Q chat ולמידת מכונה): לפחות 80% דיוק.
- משוב אבחוני יופק תוך פחות מ-3 שניות.
- תכניות למידה מותאמות אישית ייווצרו תוך 10 שניות.
- תמיכה בניתוח של 100 משתמשים במקביל.
- מינימום של 1 TB אחסון בענן לכל 1,000 תלמידים בשנה.
- התאמה לסביבות מציאותיות ולמגוון הפרעות בזמנית.
- צריכת סוללה של שעון חכם לא תעלה על 10% לשעה.
- סוללה תספיק ללפחות 8 שעות איסוף נתונים פעיל.

Design constraints 3.4:

- תפקוד תקין גם במכשירים מוגבלי משאבים (שעונים חכמים, טאבלטים).
- משימות חישוביות (כגון אימון וסיווג) יועברו לעיבוד בקליניקה או בשרת קצה.
- עמידה מלאה בתקנות GDPR, HIPAA.
- כל הנתונים יוצפנו (AES-256) בשידור ובאחסון.
- רק נתונים אנונימיים יורשו לשמש למחקר או עדכון מודלים.
- המערכת תאפשר המשך איסוף וניתוח נתונים גם כאשר אין חיבור לאינטרנט, ותבצע סנכרון אוטומטי של המידע שנאסף כאשר החיבור מתחדש.
- רכיבי הליבה (EEG, מעקב עיניים) יפעלו גם ללא חיבור לאינטרנט.
- המערכת תתמוך בעדכונים עצמאיים של מודולי למידת מכונה.
- תמיכה מלאה בפלטפורמות מוכרות כגון: TensorFlow, PyTorch, Keras.

Software system attributes 3.5:

אמינות: תספק יציבות תפעולית גבוהה ותבטיח תקינות בפלטי האבחון גם בתנאי שימוש משתנים או בתנאי עומס, על מנת לאפשר הסתמכות מקצועית על תוצריה בקרב מאבחנים ואנשי חינוך.

זמינות: זמינות לשימוש רציף לאורך זמן, תוך תמיכה בגישה מבוססת ענן מגובה, על מנת לאפשר עבודה במוסדות חינוך, קליניקות או בסביבה ביתית ללא השבתות ממושכות.

יכולת תחזוקה ועדכון: עדכון עצמאי של מודולי למידת המכונה, הוספת אלגוריתמים חדשים, ושדרוג רכיבי ממשק המשתמש ללא צורך בשכתוב כולל של הקוד.

ניידות: תתמוך בהתקנה והפעלה על גבי מגוון פלטפורמות חומרה, כולל טאבלטים, מחשבים ניידים ושעונים חכמים, תוך שמירה על עקביות בביצועים ובממשק המשתמש.

שקיפות ויכולת הסבר: תוצרי המערכת (כגון: החלטות אבחון, דירוגי סיכון, המלצות המשך טיפול) יונגשו בליווי הסברים אינטואיטיביים, על מנת לספק תמיכה בהחלטות קליניות ולהגביר את אמון המשתמשים.

השוואה של טכניקות מול קריטריונים

טכניקות / קריטריונים	שעון חכם ASD	Eye-tracking דיסלקציה	Hand-writing דיסגרפיה	אבחון ADHD - EEG	שאלון Q-CHAT
דיוק	9	9	8*	10	7
זמינות חומרה	8	5	7	3	10
יעילות נתונים	5	8	4	6	9
יכולת פרשנות ע"י אנשי מקצוע	4	5	6	4	9
ישימות בזמן אמת	8	6	5	3	9

פירוט מאפייני ההשוואה בין הטכניקות:

דיוק: עד כמה המודל הצליח לזהות את ההפרעה (ADHD/ASD/דיסלקציה/דיסגרפיה) בצורה נכונה. הנתונים מתבססים על אחוזי הצלחה שדווחו במחקרים לדוגמה: 99.75% במודל EEG ל-ADHD.

זמינות חומרה / נגישות: האם השיטה דורשת ציוד יקר או מורכב (כמו EEG קליני או Eye-tracking) או שניתן להפעילה על ציוד פשוט וזמין (כמו שעון חכם או שאלון).

יעילות נתונים: כמה נתונים דרושים כדי לאמן את המודל (כמות דגימות, חיישנים, וכו'). לדוגמה: עשרות אלפי דגימות כתיבה בכתב יד לעומת רק 300 שורות בשאלון Q-CHAT.

יכולת פרשנות (עבור אנשי חינוך / קלינאים): עד כמה ניתן להבין את אופן הפעולה של המודל ולקבל ממנו תובנות מעשיות. לדוגמה: האם ניתן להסביר מדוע התקבלה אבחנה מסוימת בעזרת משקלי משתנים, תכונות כתב או הדמיות, או שמדובר במודל שקשה להבין את ההיגיון הפנימי שלו.

ישימות בזמן אמת / התקנה על מכשירים חכמים: עד כמה המודל מסוגל לפעול מיידית. לדוגמה על גבי שעון חכם או טאבלט ללא צורך בעיבוד כבד במחשב חזק או דורש חיבור מתמשך לשרת חיצוני.

הסבר ציונים לפי קריטריונים:

דיוק:

- שעון חכם (9): דיוק גבוה (98%) במטלות מגוונות בזכות שילוב סנסורים ומודלים היברידיים (לא 10 כי יש שונות בין משימות).
- מעקב עיניים (9): זיהוי דיסלקציה בדיוק גבוה של 98.2% בקרב ילדים שונים (לא 10 כי מספר ההקלטות שעליהן בוצע האימון היה קטן יחסית).
- כתב יד (*8): השיטה הצליחה לזהות בצורה טובה את ההפרעות, אבל לא צוין אחוז דיוק מספרי ולכן ניתן ציון משוער עם כוכבית.
- אבחון ADHD באמצעות EEG (10): תוצאה מקסימלית (99.75%) על מאות הקלטות מגוונות - עקבי וברור.
- שאלון (7): דיוק 90.5% בשאלון קצר, אך מוגבל בגלל מעט פריטים ואופי סובייקטיבי.

זמינות חומרה / נגישות:

- שעון חכם (8): מבוסס על חיישנים לבישים זמינים כלומר דורש תשתית אך לא קלינית.
- מעקב עיניים (5): דורש ציוד שלא נגיש לרוב בתי הספר.
- כתב יד (7): טאבלט או עט דיגיטלי - שכיח יחסית אך יקר.
- אבחון ADHD באמצעות EEG (3): ציוד קליני מורכב עם צורך באיש מקצוע.
- שאלון (10): מילוי שאלון אונליין - זמין לכולם, ללא ציוד נוסף.

יעילות נתונים:

- שעון חכם (5): דורש תיאום בין מקורות נתונים שונים ולכן לא פשוט.
- מעקב עיניים (8): השגת ביצועים גבוהים מ-185 הקלטות - שימוש יעיל מאוד.
- כתב יד (4): 33K דגימות עם תיוג מורכב - איסוף כבד.
- אבחון ADHD באמצעות EEG (6): הדגימות בינוניות בנפח אך דורש עיבוד מוקדם של נתונים.
- שאלון (9): מאגר קטן מספיק לדיוק גבוה.

יכולת פרשנות (עבור אנשי חינוך / קלינאים):

- שעון חכם (4): המודל מורכב מרשת עמוקה שמשלבת כמה סוגי נתונים ולכן רוב תהליך קבלת ההחלטות מוסתר. מנגנון הקשב תורם מעט להבנה אך לא מספיק.
- מעקב עיניים (5): ניתן לראות אזורים במפה שהשפיעו על ההחלטה דרך מנגנון קשב, אבל המודל עדיין קשה לפירוש מלא.
- כתב יד (6): ניתן לראות את שחזור הכתב ואת תבניות התנועה שהשפיעו על האבחון ולכן המידע יותר נגיש להבנה בהשוואה למודלים אחרים.
- אבחון ADHD באמצעות EEG (4): המודל מציג אזורי זמן/תדר מסוימים, אך השילוב עם רשת נוירונים על טנסורים הופך את ההבנה למורכבת מאוד.
- שאלון (9): קל מאוד להבין מה השפיע מכיוון שכל שאלה מקבלת משקל ברור שניתן להסביר ולכן יש שקיפות גבוהה.

ישימות בזמן אמת / התקנה על מכשירים חכמים:

- שעון חכם (8): המערכת בנויה על חיישנים לבישים שמבצעים ניתוח ישירות במכשיר ולכן מאפשר פעולה כמעט מיידי בשטח.
- מעקב עיניים (6): ניתוח הקלט מתאפשר על מחשב רגיל, אך לא מותאם להרצה בזמן אמת על מכשירים פשוטים (דורש עיבוד גרפי).
- כתב יד (5): העיבוד מתבצע לרוב אחרי השלמת הכתיבה, ולכן לרוב לא מאפשר זיהוי מיידי.
- אבחון ADHD באמצעות EEG (3): דורש עיבוד כבד עם ציוד ייעודי ומעבדה, כולל ניקוי רעשים ולכן לא מתאים לזיהוי בזמן אמת או על התקנים ניידים.
- שאלון (9): הניתוח מבוסס על טופס פשוט הנותן פלט מיידי אפשרי לאחר ההזנה.

ניתוח והפקת לקחים עבור הנושא – לקויות למידה:

שאלת מחקר	טכניקה	שעון חכם לאוטיזם (Smartwatch ASD)	ניתוח EEG לאבחון ADHD	Eye-tracking לאבחון דיסלקציה	ניתוח כתב יד לאבחון דיסגרפיה	Machine Learning ASD לאבחון מוקדם
כיצד ניתן לשפר למידה של ילדים עם ASD מרחוק?	מערכת לבישה המנטרת התנהגות, קשב ורגשות בזמן אמת ומעדכנת תוכן לימודי מותאם אישית	-	-	-	-	-
כיצד ניתן לאבחן ADHD באופן מדויק ולא פולשני?	-	-	אלגוריתם ניתוח עם EEG ConvLSTM לזיהוי דפוס קשב והיפראקטיביות	-	-	-
כיצד ניתן לאתר דיסלקציה בשלבים מוקדמים?	-	-	-	Heatmaps של תנועות עיניים במבחני קריאה ומודל CNN-Transformer לזיהוי רמזים לדיסלקציה	-	-
כיצד ניתן להבחין בין דיסלקציה לדיסגרפיה?	-	-	-	-	מערכת ניתוח כתב יד המשלבת RNN LSTM עם וסיווג לקות לפי מאפיינים גיאומטריים	-
כיצד ניתן לאבחן ASD מוקדם ובאופן אובייקטיבי?	-	-	-	-	-	מאבחן אוטיזם באמצעות CNN, מאפשר גילוי מוקדם ואובייקטיבי

ניתוח והפקת לקחים RA:

טכניקה / RA	Requirements Elicitation	Stakeholders Identification	Requirements Specification
שעון חכם לאוטיזם (SM-ASDS)	מבוסס תרחישים מציאותיים עם ילדים בכיתה, ניטור חיישנים אמיתי	הורים, מורים, ילדים, מטפלים – משתתפים בתצפיות ושאלונים	נדרשים: תגובתיות גבוהה, התאמה אישית, פרטיות נתונים, ממשק נוח
EEG לאבחון ADHD	שימוש בנתוני EEG מציאותיים, שאלונים סטנדרטיים	נוירולוגים, פסיכולוגים, הורים	דרישות למודלים עם דיוק גבוה, הדמיה גרפית של קשרי מוח, אינטגרציה עם תוכנות אבחון
Eye Tracking לאבחון דיסלקציה	שילוב שאלוני קריאה אינטראקטיביים	ילדים עם חשד לדיסלקציה, מומחים להפרעות למידה	דרישות כוללות: ניטור עיניים בזמן אמת, אנונימזציה של נתוני מבט, דיוק גבוה
ניתוח כתב יד לזיהוי דיסגרפיה ודיסלקציה	איסוף מדידות דינמיות של כתב יד בזמן פעילות רגילה	מורים, מאבחנים דידקטיים, קלינאי תקשורת	דרישות: ניתוח גראפי מדויק, סיווג תלת-רמות (רגיל, דיסגרפיה, דיסלקציה), חוויית משתמש לילד
Machine Learning על MRI לאבחון ASD מוקדם	איסוף נתוני MRI פתוחים, פילוח לפי קבוצות גיל ואבחון קוגניטיבי	חוקרים, רופאים, אנשי הדמיה, מטפלים בילדים עם ASD	דיוק אבחוני גבוה, עיבוד נתונים רפואיים, הגנה על פרטיות, שילוב במערכות בריאות ציבוריות

1. Smart Autism Spectrum Disorder Learning System Based on Remote Edge Healthcare Clinics and Internet of Medical Things, Mohammed Mazin Abed, Alyahya Saleh, Mukhlif Abdulrahman Abbas, Abdulkareem Karrar Hameed, Hamouda Hassen, Lakhan Abdullah, *Sensors*, Volume 24, Issue 23, December 2024
Student - Alika Bochkaryov

2. Eye-tracking based Detection of Developmental Dyslexia in Children Using Convolutional-Transformer Network,
Li Xin, Li Zhongjie, Xu Feiyang
Student - Ehab Marrid

3. Detection of ADHD Disorder Using Dynamic Connectivity Tensors in Bidirectional Circular Reservoir Computing,
Bakhtyari Mohammadreza, Mirzaei Sayeh,
2021 28th National and 6th International Iranian Conference on Biomedical Engineering, ICBME 2021.
Student - Tali Michaeli

4. Enhancing Early Diagnosis of Autism Spectrum Disorder in Children: A Comparative Analysis of Machine Learning Techniques,
Tripathi, Ashish, Gupta, Rohit Kumar, Sharma, Muskan
Lecture Notes in Networks and Systems, Volume 1116 LNNS, 2024.
Student - Saar Avivi

5. Handwriting Anomalies and Learning Disabilities through Recurrent Neural Networks and Geometric Pattern Analysis 5th International Conference on Electrical, Communication and Computer Engineering, ICECCE 2024.
Student - Ron Afriat